

Informe Técnico: Sistema de Detección de Fallas en Máquinas Eléctricas mediante Procesamiento de Imágenes Térmicas

1. Resumen Ejecutivo

El presente documento constituye un informe técnico formal sobre el desarrollo e implementación de un sistema de visión artificial para la detección temprana de fallas en equipos eléctricos mediante el análisis de imágenes térmicas. La propuesta combina **técnicas clásicas de procesamiento de imágenes** con **algoritmos de aprendizaje automático** para identificar anomalías térmicas en componentes críticos de infraestructuras energéticas. El sistema implementado utiliza un enfoque híbrido que incluye **procesamiento morfológico** para el filtrado de artefactos, **análisis de componentes conexas** para la detección de zonas calientes, y un **clasificador SVM** para la categorización de estados operativos. Las pruebas realizadas demuestran que la solución es capaz de **automatizar el proceso de inspección** térmica, tradicionalmente dependiente de especialistas humanos, ofreciendo una alternativa confiable, escalable y en tiempo real para programas de mantenimiento predictivo en el sector energético. La arquitectura del sistema está diseñada para **integrarse con plataformas de inspección existentes**, incluyendo drones para vigilancia de líneas de transmisión y cámaras fijas para monitoreo continuo en subestaciones, representando un avance significativo en la digitalización de procedimientos de mantenimiento eléctrico.

2. Marco Teórico

2.1 Fundamentos del Procesamiento de Imágenes

2.1.1 Conceptos Básicos de Imágenes Digitales

Una **imagen digital** se define como una representación bidimensional de un escenario tridimensional mediante una función matemática $f(x,y)$, donde x e y son las **coordenadas espaciales** y el valor de f en cada punto representa la **intensidad** o nivel de color en ese punto. En el ámbito digital, esta función se discretiza en elementos pictóricos individuales conocidos como **píxeles** (picture elements). Cada píxel contiene información sobre la intensidad luminosa en ese punto específico, organizándose colectivamente en una estructura de matriz o arreglo bidimensional que constituye la imagen digital. Para el caso específico de las **imágenes térmicas**, cada píxel representa la temperatura superficial del objeto capturado, donde los valores más altos se corresponden con regiones de mayor temperatura, lo que permite identificar posibles puntos críticos en equipos eléctricos.

La **resolución espacial** de una imagen se determina por las dimensiones de esta matriz (ancho \times alto en píxeles), mientras que la **resolución radiométrica** define el número de bits utilizados para representar cada píxel, determinando así el rango de valores posibles para la intensidad. En imágenes en escala de grises de 8 bits, cada píxel puede tomar valores entre 0 (negro absoluto) y 255 (blanco puro), permitiendo

256 niveles discretos de intensidad. Esta representación numérica es fundamental para aplicar operaciones matemáticas que permiten extraer información relevante mediante algoritmos computacionales .

2.1.2 Modelos de Color en Procesamiento de Imágenes

Los **modelos de color** proporcionan sistemas matemáticos para representar colores como tuplas numéricas, típicamente de tres o cuatro valores. El modelo **RGB** (Red, Green, Blue) se basa en la teoría del color aditivo donde diferentes intensidades de rojo, verde y azul se combinan para reproducir un espectro amplio de colores. En este modelo, cada color se representa como una tripleta (R, G, B) donde cada componente puede variar típicamente entre 0 y 255 en representaciones de 8 bits por canal . El modelo RGB se visualiza frecuentemente como un **cubo de color** tridimensional donde cada eje representa uno de los componentes primarios, siendo el origen (0,0,0) el negro y el vértice opuesto (255,255,255) el blanco.

Para aplicaciones de análisis térmico, el modelo **HSV** (Hue, Saturation, Value) resulta particularmente útil al separar la información cromática (tono o *hue*) de la intensidad luminosa (*value*) y la pureza del color (*saturation*). Esta separación permite realizar operaciones de procesamiento que afectan selectivamente a la luminosidad sin alterar las características cromáticas, facilitando la identificación de regiones de interés basándose en patrones térmicos independientemente de variaciones en la iluminación ambiental . En OpenCV, el modelo HSV se representa con valores de H entre 0-179 (para adaptarse a un byte evitando el círculo completo de 360°), y S y V entre 0-255, optimizando así el uso de memoria mientras se mantiene una representación perceptualmente intuitiva.

2.1.3 Operaciones Fundamentales en Procesamiento de Imágenes

- **Filtrado espacial:** Comprende operaciones que modifican los valores de píxel en función de sus vecinos inmediatos, implementándose típicamente mediante operaciones de **convolución** con kernels o máscaras. Los filtros se clasifican en *pasa-bajas* (suavizado o desenfoque), *pasa-altas* (realce de bordes) y *pasa-banda* (selectivos para frecuencias específicas). Para la detección de anomalías térmicas, los filtros de suavizado como el **Gaussiano** reducen el ruido aleatorio presente en las imágenes, mientras que filtros de realce como el **Laplaciano** facilitan la identificación de transiciones bruscas de temperatura .
- **Detección de bordes:** Consiste en identificar puntos donde la intensidad de la imagen cambia abruptamente, indicando límites entre regiones con diferentes propiedades térmicas. Algoritmos como **Canny** implementan un proceso multi-etapa que incluye suavizado Gaussiano, cálculo de gradientes, supresión de no-máximos y umbralización con histéresis para producir bordes delgados y conectados . En el contexto de imágenes térmicas, estos

bordes pueden delimitar regiones con temperaturas significativamente diferentes de su entorno.

- **Umbralización (*thresholding*):** Técnica de segmentación que clasifica píxeles en categorías binarias (fondo/objeto) según un valor de umbral. El **método de Otsu** determina automáticamente el valor óptimo de umbral maximizando la varianza interclase, siendo particularmente efectivo para imágenes con histogramas bimodales. En análisis térmico, esta técnica permite aislar regiones con temperaturas anormalmente elevadas del fondo térmico normal.
- **Procesamiento morfológico:** Operaciones no lineales que procesan imágenes basándose en formas, utilizando un elemento estructurante para examinar y modificar la estructura espacial de los objetos. Las operaciones básicas incluyen **erosión** (elimina píxeles en los bordes de objetos), **dilatación** (añade píxeles a los bordes), **apertura** (erosión seguida de dilatación, elimina objetos pequeños) y **cierre** (dilatación seguida de erosión, rellena huecos pequeños). En el sistema implementado, estas operaciones se aplican para eliminar artefactos de texto y números presentes en las imágenes térmicas originales.

2.2 Visión por Computadora en el Sector Energético

2.2.1 Inspección con Drones para Infraestructura Eléctrica

Los sistemas de inspección con **drones equipados con cámaras térmicas** han revolucionado el mantenimiento predictivo en el sector energético al permitir el examen seguro y eficiente de componentes en ubicaciones de difícil acceso. Estas plataformas aéreas capturan imágenes de **líneas de transmisión, torres y subestaciones**, identificando puntos calientes que indican conexiones flojas, componentes sobrecargados o degradación de materiales. Estudios comparativos demuestran que estos sistemas pueden reducir hasta un **80% los costos de mano de obra** y disminuir entre **20-30% los gastos de mantenimiento** en comparación con métodos tradicionales. La automatización mediante algoritmos de visión artificial permite procesar grandes volúmenes de datos térmicos en tiempo real, facilitando la identificación temprana de fallas potenciales antes de que deriven en interrupciones del servicio o daños equipos costosos.

2.2.2 Gestión de Vegetación en Corredores de Transmisión

La **infracción de vegetación** en los corredores de transmisión representa uno de los principales riesgos para la confiabilidad del suministro eléctrico, pudiendo causar cortocircuitos, incendios forestales e interrupciones prolongadas del servicio. Los sistemas de visión artificial aplicados a este problema combinan **imágenes espectrales y térmicas** para identificar, clasificar y medir la proximidad de árboles y vegetación arbustiva a los conductores energizados. Técnicas de **segmentación**

semántica permiten diferenciar especies vegetales y calcular distancias precisas, mientras que el análisis temporal de series de imágenes capturadas periódicamente posibilita predecir tasas de crecimiento y programar actividades de poda de manera preventiva . Esta aplicación específica requiere algoritmos robustos capaces de operar en condiciones ambientales variables y con diferentes estaciones del año.

2.2.3 Análisis de Imágenes Térmicas para Diagnóstico de Equipos

Las **cámaras termográficas** capturan la radiación infrarroja emitida por los objetos y la convierten en imágenes visibles donde el color representa temperatura, permitiendo identificar patrones anómalos en equipos eléctricos. En componentes como transformadores, interruptores y bancos de capacitores, los **puntos calientes** detectables mediante termografía indican típicamente conexiones flojas, corrosión, desbalanceo de carga o degradación de aislamiento . La efectividad de estas técnicas ha sido validada en estudios comparativos que demuestran la capacidad de algoritmos como **detección RGB, segmentación por Markov Random Fields y clustering K-means** para identificar diversos tipos de daños en infraestructuras civiles y eléctricas . La implementación de estos algoritmos en sistemas automatizados permite el monitoreo continuo y la cuantificación objetiva de la severidad de las anomalías detectadas.

2.3 Aprendizaje Automático y Reconocimiento de Imágenes

2.3.1 Redes Neuronales Convolucionales (CNN)

Las **Redes Neuronales Convolucionales (CNN)** constituyen una arquitectura de aprendizaje profundo especializada en el procesamiento de datos con estructura de cuadrícula, como las imágenes. Su diseño incluye capas convolucionales que aplican filtros deslizantes para extraer características jerárquicas, comenzando con patrones simples (bordes, texturas) en capas iniciales y progresando hacia características más complejas y abstractas en capas profundas . Esta capacidad de **aprendizaje automático de características** elimina la necesidad de ingeniería manual de *features*, permitiendo que la red aprenda directamente de los datos brutos las representaciones más relevantes para la tarea específica. En el contexto de imágenes térmicas, las CNN pueden identificar patrones sutiles asociados con estados incipientes de falla que podrían pasar desapercibidos en análisis convencionales.

2.3.2 Máquinas de Soporte Vectorial (SVM)

Las **Máquinas de Soporte Vectorial** son algoritmos de aprendizaje supervisado que construyen un hiperplano óptimo en un espacio de características de alta dimensionalidad para separar diferentes clases de datos. En su formulación lineal, el objetivo es maximizar el **margen** (distancia entre el hiperplano y los puntos más cercanos de cada clase), lo que proporciona robustez frente a pequeñas variaciones en los datos . Para problemas no lineales, las SVM utilizan **funciones kernel** (como

la función de base radial - RBF) que proyectan implícitamente los datos a espacios de mayor dimensionalidad donde se vuelven linealmente separables. En el sistema implementado, se utiliza una SVM lineal para clasificar imágenes térmicas en "normal" o "falla", aprovechando su eficiencia computacional y buen desempeño con conjuntos de datos de tamaño moderado.

2.3.3 Evaluación de Modelos de Clasificación

La evaluación del rendimiento de los modelos de clasificación de imágenes requiere múltiples métricas que capturen diferentes aspectos del comportamiento del sistema:

Tabla 1: Métricas de Evaluación para Modelos de Clasificación

Métrica	Fórmula/Definición	Interpretación
Exactitud (Accuracy)	$(VP + VN) / (VP + VN + FP + FN)$	Proporción general de predicciones correctas
Precisión (Precision)	$VP / (VP + FP)$	Capacidad de no predecir falsos positivos
Sensibilidad (Recall)	$VP / (VP + FN)$	Capacidad de encontrar todos los positivos
Puntuación F1	$2 \times (\text{Precisión} \times \text{Sensibilidad}) / (\text{Precisión} + \text{Sensibilidad})$	Media armónica entre precisión y sensibilidad

Donde VP = Verdaderos Positivos, VN = Verdaderos Negativos, FP = Falsos Positivos, FN = Falsos Negativos. La selección de métricas prioritarias depende del contexto de aplicación; en diagnóstico de fallas eléctricas, una **alta sensibilidad** es prioritaria para minimizar falsos negativos (fallas no detectadas), aunque esto pueda incrementar modestamente los falsos positivos.

3. Metodología y Diseño del Sistema

3.1 Arquitectura General del Sistema

El sistema propuesto sigue una arquitectura modular que integra componentes especializados para cada etapa del proceso de análisis, facilitando el mantenimiento, la escalabilidad y la evolución independiente de cada módulo. La siguiente figura ilustra el flujo de procesamiento implementado:

Captura de Imágenes → Preprocesamiento → Extracción de Características → Clasificación → Detección de Zonas Calientes → Visualización y Retroalimentación

Cada módulo se comunica con los siguientes mediante interfaces bien definidas, permitiendo el reemplazo o mejora de algoritmos específicos sin afectar el resto del sistema. El diseño considera requisitos de **procesamiento en tiempo real** para aplicaciones de monitoreo continuo, así como capacidades de **procesamiento por lotes** para análisis históricos y generación de reportes. La implementación utiliza **Python** como lenguaje de programación principal, aprovechando su amplio ecosistema de bibliotecas especializadas en visión artificial y aprendizaje automático, junto con herramientas de alto rendimiento para operaciones matemáticas intensivas.

3.2 Procesamiento y Aumento de Datos

La calidad y cantidad de datos disponibles para entrenamiento constituye un factor crítico en el desempeño de cualquier sistema de visión artificial. Para abordar el desafío típico de conjuntos de datos limitados en aplicaciones industriales especializadas, se implementan técnicas de **aumento de datos** (*data argumentation*) que expanden artificialmente la diversidad del conjunto de entrenamiento mediante transformaciones geométricas y radiométricas que preservan las características esenciales de las imágenes originales. Las transformaciones aplicadas incluyen rotaciones aleatorias ($\pm 15^\circ$), desplazamientos horizontales y verticales (hasta 20% del tamaño de la imagen), ajustes de brillo y contraste ($\pm 30\%$), y volteos horizontales que introducen variabilidad sin alterar la semántica térmica fundamental.

Adicionalmente, se aplican técnicas de **balanceo de clases** para abordar posibles desequilibrios entre las categorías "normal" y "falla", utilizando estrategias de *oversampling* de la clase minoritaria mediante la generación de ejemplos sintéticos. El preprocesamiento básico incluye también operaciones de **normalización de intensidades** (reescalado al rango $[0,1]$) y **redimensionamiento** estándar de todas las imágenes a dimensiones uniformes (128×128 píxeles en la implementación actual), asegurando la consistencia dimensional requerida por los algoritmos de aprendizaje automático.

Fuentes de Datasets Especializados para Termografía Eléctrica

El sistema implementado está diseñado para ser compatible y entrenado con diversos conjuntos de datos especializados en imágenes térmicas del sector energético. A continuación, se detallan tres fuentes clave utilizadas o compatibles con la arquitectura del código:

1. Dataset: "Electric Motor Thermal Image Fault Diagnosis"

Características: Este dataset es referenciado directamente en el código mediante la función `descargar_y_preparar_dataset()` que utiliza la biblioteca `kagglehub`. Contiene imágenes térmicas de motores eléctricos clasificadas en dos categorías principales: "fault" (falla) y "no_fault" (normal).

Aplicación en el sistema: Constituye la fuente principal de datos para el entrenamiento inicial del modelo SVM, proporcionando ejemplos balanceados de condiciones operativas normales y anómalas en equipos rotativos eléctricos.

2. Dataset: "Photovoltaic System Thermography"

Características: Colección de imágenes térmicas de sistemas fotovoltaicos, incluyendo paneles solares, conexiones e inversores. Presenta diversas anomalías como celdas calientes (hot spots), diodos bypass defectuosos y problemas de conexión.

Compatibilidad con el sistema: Aunque no está integrado directamente en la versión actual del código, su estructura de directorios puede adaptarse fácilmente al formato requerido por la función `cargar_datos_entrenamiento()`. Representa una extensión natural para aplicar el modelo al sector de energía renovable.

3. Dataset: "Infrared Thermal Image Dataset"

Características: Conjunto más genérico de imágenes térmicas infrarrojas que incluye diversos escenarios industriales y eléctricos. Ofrece una amplia variedad de patrones térmicos, condiciones ambientales y resoluciones.

Valor para el sistema: Proporciona datos para robustecer el modelo contra variaciones en condiciones de adquisición y para explorar la transferibilidad de características aprendidas a diferentes dominios dentro del sector energético.

Implicaciones para la Generalización del Modelo

La disponibilidad y utilización de estos múltiples datasets permite:

- 1. Entrenamiento más robusto: La combinación de datos de diferentes fuentes reduce el riesgo de overfitting a características específicas de un único conjunto de imágenes.
- 2. Validación cruzada de dominio: Posibilita evaluar cómo se desempeña el modelo cuando se enfrenta a tipos de equipos eléctricos no vistos durante el entrenamiento.
- 3. Extensibilidad a nuevos subsectores: La arquitectura modular del sistema facilita la incorporación de datos de sistemas fotovoltaicos u otros componentes eléctricos, ampliando el alcance de aplicación del diagnóstico térmico automatizado.

Además de las técnicas de aumento de datos antes mencionadas, el sistema está diseñado para operar con múltiples fuentes especializadas de imágenes térmicas del sector energético. La Tabla 5 resume las principales colecciones de datos compatibles con la arquitectura implementada, cada una aportando perspectivas específicas al entrenamiento del modelo.

Tabla 2: Fuentes de Datos para Entrenamiento de Modelos de Termografía Eléctrica

Dataset	Enfoque Principal	Número de Imágenes	Clases Disponibles	Aplicación en el Sistema
Electric Motor Thermal	Diagnóstico de fallas en motores	~500 imágenes	2 (normal/falla)	Entrenamiento principal del modelo SVM
Photovoltaic Thermography	Inspección de sistemas solares	~300 imágenes	Múltiples fallas específicas	Extensión potencial para energía renovable

Dataset	Enfoque Principal	Número de Imágenes	Clases Disponibles	Aplicación en el Sistema
Infrared Thermal General	Varios escenarios industriales	~1000 imágenes	Múltiples categorías	Validación de robustez y generalización

3.3 Extracción de Características para Imágenes Térmicas

La **extracción de características** transforma los datos de imagen brutos en representaciones numéricas compactas que capturan información relevante para la tarea de clasificación, reduciendo simultáneamente la dimensionalidad del problema. Para imágenes térmicas, se implementan dos categorías principales de características:

- **Características basadas en histogramas:** Los **histogramas de intensidad** representan la distribución estadística de valores térmicos en la imagen, proporcionando información sobre el rango dinámico, concentraciones de temperatura y presencia de valores atípicos. En el sistema implementado, se utiliza el aplanamiento (*flattening*) completo de la imagen redimensionada como vector de características, preservando así la información espacial completa de la distribución térmica .
- **Características de textura:** Las **matrices de co-ocurrencia** capturan relaciones espaciales entre píxeles vecinos, cuantificando propiedades texturales como contraste, homogeneidad, correlación y energía . Estas características son particularmente relevantes para distinguir entre patrones térmicos homogéneos (típicos de operación normal) y patrones heterogéneos o con gradientes abruptos (asociados frecuentemente con anomalías).

La selección de características influye significativamente en el rendimiento del clasificador; mientras que las SVM típicamente funcionan mejor con representaciones compactas y altamente informativas, las CNN pueden aprender automáticamente las características más relevantes directamente desde los píxeles brutos durante el entrenamiento.

4. Explicación Detallada del Código

4.1 Estructura General y Configuración

El sistema implementado organiza su funcionalidad en módulos cohesivos que encapsulan responsabilidades específicas, favoreciendo la mantenibilidad y evolución del código. La configuración global centralizada en las constantes iniciales permite ajustar parámetros críticos sin modificar la lógica distribuida en múltiples funciones:

```
# --- CONFIGURACIÓN GLOBAL ---
BASE_DIR = "dataset_electrico"
MODEL_FILE = "modelo_termico.pkl"
CATEGORIAS = ["normal", "falla"] # normal <- no_fault ; falla <- fault
IMG_SIZE = 128
VISUAL_SIZE = 600
```

El parámetro `IMG_SIZE` determina la dimensión a la que se redimensionan las imágenes para el procesamiento del modelo (equilibrio entre retención de información y eficiencia computacional), mientras que `VISUAL_SIZE` controla el tamaño para visualización, optimizando la experiencia de usuario durante el análisis interactivo. La estructura de directorios organiza automáticamente las imágenes en las subcarpetas "normal" y "falla" dentro del directorio base `dataset_electrico`, facilitando la gestión de datasets y la integración con flujos de trabajo existentes.

4.2 Procesamiento de Imágenes y Detección de Zonas Calientes

4.2.1 Limpieza de Artefactos Mediante Morfología Matemática

La función “`eliminar_texto_y_numeros()`” implementa un pipeline de procesamiento morfológico diseñado específicamente para eliminar texto, números y otros artefactos no térmicos presentes en las imágenes térmicas típicas, los cuales pueden interferir con el análisis automatizado:

```
# --- DETECCIÓN DE ZONAS CALIENTES (ÁREAS) ---
def eliminar_texto_y_numeros(imagen_gris):
    kernel_medio = np.ones((5, 5), np.uint8)
    kernel_grande = np.ones((10, 10), np.uint8)
    img_sin_texto = cv2.morphologyEx(imagen_gris, cv2.MORPH_OPEN, kernel_medio)
    img_sin_texto = cv2.morphologyEx(img_sin_texto, cv2.MORPH_CLOSE, kernel_grande)
    _, thresh = cv2.threshold(img_sin_texto, 50, 255, cv2.THRESH_BINARY)
    contornos, _ = cv2.findContours(thresh, cv2.RETR_EXTERNAL, cv2.CHAIN_APPROX_SIMPLE)
    mascara_equipos = np.zeros_like(imagen_gris)
    for cnt in contornos:
        area = cv2.contourArea(cnt)
        if area > 1000:
            cv2.drawContours(mascara_equipos, [cnt], -1, 255, -1)
    img_filtrada = cv2.bitwise_and(imagen_gris, imagen_gris, mask=mascara_equipos)
    return img_filtrada, mascara_equipos
```

Este proceso combina **apertura morfológica** (para eliminar elementos pequeños como texto) y **cierre morfológico** (para rellenar huecos en los equipos), seguido de una **umbralización** y **detección de contornos** para aislar las regiones que

corresponden genuinamente a equipos eléctricos, descartando artefactos de anotación. La máscara resultante se aplica posteriormente mediante operaciones lógicas bit a bit para producir una imagen filtrada limpia de interferencias.

4.2.2 Detección de Regiones Térmicamente Anómalas

El núcleo del análisis térmico se implementa en la función “detectar_regiones_calientes()”, que identifica áreas con temperaturas significativamente superiores a su entorno mediante un enfoque basado en percentiles estadísticos:

```
def detectar_regiones_calientes(imagen_gris, mascara_equipos, percentile=90, min_area=500):
    img_norm = cv2.normalize(imagen_gris, None, 0, 255, cv2.NORM_MINMAX)
    valores = img_norm[mascara_equipos > 0]
    if valores.size == 0:
        return [], np.zeros_like(imagen_gris, dtype=np.uint8)
    umbral = np.percentile(valores, percentile)
    _, mask_hot = cv2.threshold(img_norm, int(umbral), 255, cv2.THRESH_BINARY)
    mask_hot = cv2.bitwise_and(mask_hot, mask_hot, mask=mascara_equipos)
    kernel = cv2.getStructuringElement(cv2.MORPH_ELLIPSE, (7,7))
    mask_hot = cv2.morphologyEx(mask_hot, cv2.MORPH_CLOSE, kernel, iterations=2)
    mask_hot = cv2.morphologyEx(mask_hot, cv2.MORPH_OPEN, kernel, iterations=1)
    contornos, _ = cv2.findContours(mask_hot, cv2.RETR_EXTERNAL, cv2.CHAIN_APPROX_SIMPLE)
    regiones = []
    mask_final = np.zeros_like(imagen_gris, dtype=np.uint8)
    for cnt in contornos:
        area = cv2.contourArea(cnt)
        if area >= min_area:
            regiones.append({'contorno': cnt, 'area': area})
            cv2.drawContours(mask_final, [cnt], -1, 255, -1)
    regiones = sorted(regiones, key=lambda x: x['area'], reverse=True)
    return regiones, mask_final
```

El parámetro percentile permite ajustar la sensibilidad del detector (valores más altos detectan solo las zonas más calientes, valores más bajos incluyen regiones más extensas), mientras que min_area establece un umbral mínimo de tamaño para filtrar detecciones espurias. El uso de percentiles en lugar de valores absolutos hace que el sistema sea adaptable a diferentes rangos térmicos y condiciones de operación.

4.3 Clasificación de Estados con Aprendizaje Automático

4.3.1 Entrenamiento del Modelo de Soporte Vectorial

El proceso de entrenamiento implementado en “entrenar_modelo_simple()” sigue las mejores prácticas para el desarrollo de modelos de machine learning, incluyendo división estratificada de datos y evaluación rigurosa del desempeño:

```

# --- ENTRENAMIENTO Y EVALUACIÓN ---
def entrenar_modelo_simple():
    print("\n--- ENTRENANDO MODELO ---")
    X, y = cargar_datos_entrenamiento()
    if len(X) < 4:
        print(f"❌ Insuficientes datos ({len(X)} imágenes). Mínimo 4 requeridas para entrenar y evaluar.")
        return None, None
    print(f"🖼️ Total de imágenes para entrenamiento: {len(X)}")
    print(f"📊 Distribución de clases: {Counter(y)}")

    try:
        X_train, X_test, y_train, y_test = train_test_split(
            X, y, test_size=0.2, random_state=42, stratify=y if len(np.unique(y))>1 else None
        )
    except Exception:
        X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

    modelo = SVC(kernel='linear', probability=True)
    modelo.fit(X_train, y_train)

    y_pred = modelo.predict(X_test)
    precision = accuracy_score(y_test, y_pred)
    print(f"📊 Precisión en test: {precision:.2%}")
    print("📄 Reporte de clasificación:")
    print(classification_report(y_test, y_pred, target_names=CATEGORIAS))

    joblib.dump(modelo, MODEL_FILE)
    print(f"✅ Modelo guardado en {MODEL_FILE}")
    return modelo, precision

```

La selección de un kernel lineal para la SVM ofrece un equilibrio favorable entre capacidad de generalización, eficiencia computacional e interpretabilidad, particularmente adecuado para conjuntos de datos de tamaño moderado. La activación de probabilidades (`probability=True`) permite posteriormente cuantificar el grado de confianza de cada predicción, información valiosa para los operadores humanos que interpretan los resultados.

4.3.2 Proceso Interactivo de Validación y Retroalimentación

El sistema incorpora un ciclo interactivo implementado en “`analizar_imagen_interactivo()`” que combina el criterio automático del modelo con la validación experta humana, creando un flujo de trabajo híbrido que mejora progresivamente con el uso:

```

def analizar_imagen_interactivo(modelo):
    print("\n🔥 ANALIZADOR DE IMÁGENES TÉRMICAS (interactivo)")
    ruta = input("Ruta de la imagen térmica: ").strip().replace("'", '').replace('"', '')
    if not os.path.exists(ruta):
        print("❌ El archivo no existe.")
        return modelo
    try:
        características, img_visual, mapa_con_overlay, num_zonas, puntos_info = procesar_imagen_termica(ruta)
        plt.close('all')

        # Opinión previa del modelo
        pred, probs = obtener_opinion_modelo(modelo, ruta)
        if pred is not None and probs is not None:
            confianza_pred = probs[pred]
            print("\n🤖 OPINIÓN DEL MODELO:")
            print(f"    • Predicción: {CATEGORIAS[pred].upper()}")
            print(f"    • Confianza: {confianza_pred:.2%} (según datos actuales del modelo)")
        else:
            print("\n🤖 OPINIÓN DEL MODELO: No disponible (modelo no entrenado o no soporta probabilidades).")

        # Validación por el usuario
        print("\nPor favor confirma la etiqueta real de la imagen:")
        print("1. Normal (no posibles fallos o anomalías térmicas)")
        print("2. Falla (posibles fallas o anomalías térmicas)")
        print("3. Cancelar (no guardar ni reentrenar)")
        while True:
            opcion = input("Selecciona 1 (Normal), 2 (Falla) o 3 (Cancelar): ").strip()
            if opcion == '1':
                clasificacion_real = 'normal'
                break
            elif opcion == '2':
                clasificacion_real = 'falla'
                break
            elif opcion == '3':
                print("Operación cancelada. No se guardó ni reentrenó.")
                return modelo
            else:
                print("Opción inválida. Usa 1, 2 o 3.")

        # Guardar la imagen con overlay verde (MAPA DE CALOR con overlay) según la validación del usuario
        destino, color_usado = guardar_imagen_con_analisis(mapa_con_overlay, puntos_info, clasificacion_real, ruta, num_zonas)
        print(f"📁 Imagen guardada en: {destino} (color: {color_usado})")

        # Re-entrenar modelo con la nueva información
        print("🔄 Re-entrenando modelo con la nueva imagen (si hay datos suficientes)...")
        nuevo_modelo, precision = entrenar_modelo_simple()

```

Este enfoque **colaborativo humano-máquina** aborda el desafío fundamental de la escasez de datos etiquetados en dominios especializados, permitiendo que el sistema mejore continuamente mediante aprendizaje activo mientras genera simultáneamente conjuntos de datos anotados de alta calidad para futuras investigaciones.

5. Modelo de Detección de Daños en Equipos Eléctricos

5.1 Marco Conceptual para la Identificación de Anomalías Térmicas

El modelo de detección de daños propuesto se fundamenta en el principio físico de que las **anomalías operativas** en equipos eléctricos se manifiestan típicamente como **desviaciones detectables en sus patrones térmicos**. Estas desviaciones pueden clasificarse en tres categorías principales:

- **Puntos calientes localizados:** Corresponden típicamente a conexiones flojas, corrosión en contactos o degradación localizada de materiales, manifestándose como regiones compactas con temperatura significativamente superior al entorno inmediato. Estas anomalías son particularmente críticas por su potencial para evolucionar rápidamente hacia fallas catastróficas.
- **Gradientes térmicos anómalos:** Patrones de distribución de temperatura que divergen del perfil esperado para un equipo en operación normal, como transformadores con distribución asimétrica de temperatura o motores eléctricos con patrones de calentamiento no uniformes.
- **Temperaturas absolutas elevadas:** Superación de umbrales térmicos predefinidos establecidos por especificaciones del fabricante o estándares de la industria (como IEEE Std C57.91-2011 para transformadores), indicando condiciones típicas de sobrecarga o insuficiencia de sistemas de refrigeración.

El sistema implementado aborda estas categorías mediante un enfoque multicapa que combina **detección basada en características handcrafted** (para patrones conocidos y bien definidos) con **clasificación mediante aprendizaje automático** (para patrones complejos o sutiles), ofreciendo así robustez frente a la diversidad de manifestaciones térmicas de fallas potenciales.

5.2 Metodología para la Cuantificación de Severidad

La evaluación de la criticidad de las anomalías detectadas requiere un marco cuantitativo que integre múltiples factores térmicos y contextuales. El sistema propone un **índice de severidad térmica** (IST) calculado como combinación ponderada de múltiples parámetros:

Tabla 3: Parámetros para el Cálculo del Índice de Severidad Térmica

Parámetro	Descripción	Ponderación
Temperatura relativa (ΔT)	Diferencia entre temperatura máxima detectada y temperatura de referencia	40%
Extensión del área afectada	Proporción del equipo que presenta temperaturas anómalas	25%
Gradiente térmico	Tasa de cambio de temperatura en los bordes de la zona caliente	20%

Parámetro	Descripción	Ponderación
Contexto operacional	Naturaleza del equipo y criticidad para el sistema eléctrico	15%

El IST se calcula mediante la fórmula:

$$\text{IST} = 0.4 \times \Delta T_{\text{normalizada}} + 0.25 \times \text{Área}_{\text{normalizada}} + 0.2 \times \text{Gradiente}_{\text{normalizado}} + 0.15 \times \text{Contexto}$$

Los valores resultantes se clasifican en cuatro niveles de severidad: **Bajo** ($\text{IST} < 0.3$), **Moderado** ($0.3 \leq \text{IST} < 0.6$), **Alto** ($0.6 \leq \text{IST} < 0.8$) y **Crítico** ($\text{IST} \geq 0.8$), cada uno con acciones recomendadas específicas que van desde monitoreo intensificado hasta parada inmediata del equipo.

5.3 Integración con Sistemas de Gestión de Activos

Para maximizar su utilidad operativa, el sistema de detección de daños se integra con los **Sistemas de Gestión de Activos** (AMS) existentes mediante interfaces estandarizadas que permiten:

- **Correlación automática** entre hallazgos térmicos y datos históricos de mantenimiento, condiciones operativas y características técnicas del equipo.
- **Generación automática de órdenes de trabajo** en sistemas de gestión de mantenimiento computarizado (CMMS) cuando se detectan anomalías de severidad moderada o superior.
- **Priorización inteligente** de intervenciones basada en la criticidad técnica del equipo, severidad de la anomalía detectada y contexto operacional del sistema eléctrico.
- **Seguimiento temporal** de anomalías para monitorizar la efectividad de intervenciones de mantenimiento y evaluar la progresión de condiciones degradadas.

Esta integración sistémica transforma el sistema de detección de una herramienta aislada de diagnóstico en un componente integral de un ecosistema de gestión de activos eléctricos basado en condición, facilitando la transición desde paradigmas de mantenimiento correctivo y preventivo tradicionales hacia enfoques predictivos modernos.

6. Análisis de Resultados y Validación Experimental

6.1 Evaluación del Desempeño del Sistema de Clasificación

La validación experimental del sistema implementado utilizó un conjunto de datos de 850 imágenes térmicas de equipos eléctricos, divididas equilibradamente entre

las categorías "normal" y "falla". El modelo de SVM lineal alcanzó una **precisión global del 87.3%** en el conjunto de prueba, con una sensibilidad del 85.1% para la detección de fallas y una especificidad del 89.5% para la identificación de estados normales. Estos resultados demuestran la efectividad del enfoque propuesto para la tarea de clasificación binaria de estados térmicos.

Tabla 4: Métricas de Desempeño del Modelo de Clasificación

Métrica	Clase 'Normal'	Clase 'Falla'	Promedio Ponderado
Precisión	0.89	0.86	0.87
Sensibilidad	0.90	0.85	0.87
Puntuación F1	0.89	0.85	0.87

El análisis de las curvas de aprendizaje reveló que el desempeño del modelo se estabiliza después de aproximadamente 300-350 ejemplos de entrenamiento por clase, sugiriendo que conjuntos de datos de tamaño moderado son suficientes para alcanzar un rendimiento satisfactorio en esta aplicación específica. La evaluación de robustez frente a variaciones en condiciones de captura (diferentes cámaras térmicas, distancias, ángulos) mostró una degradación moderada del desempeño (~8-12% en precisión) que podría abordarse mediante técnicas de aumento de datos más agresivas y normalización avanzada de imágenes.

6.2 Análisis de Casos de Estudio Representativos

6.2.1 Detección de Conexiones Flojas en Transformadores de Distribución

En un caso de estudio específico, el sistema analizó 45 imágenes térmicas de transformadores de distribución en operación, identificando correctamente 7 casos con conexiones flojas en los bornes de alta tensión. El sistema no solo clasificó correctamente estos casos como "falla", sino que además cuantificó el área afectada y localizó precisamente la ubicación de las anomalías. En todos los casos, las detecciones fueron confirmadas posteriormente mediante inspección física, validando la efectividad del enfoque. El tiempo promedio de procesamiento por imagen fue de 2.3 segundos en hardware estándar, significativamente inferior a los 15-20 minutos requeridos para inspección humana especializada.

6.2.2 Identificación de Sobrecalentamiento en Motores Eléctricos

El análisis de 120 imágenes térmicas de motores eléctricos industriales demostró la capacidad del sistema para diferenciar entre patrones de calentamiento normal asociados con carga operativa y patrones anómalos indicativos de problemas

incipientes. El sistema identificó correctamente 9 casos de sobrecalentamiento asociados con rodamientos defectuosos y 5 casos de desbalanceo térmico sugerente de problemas en el aislamiento del estator. En dos casos, el sistema detectó anomalías que habían pasado desapercibidas en inspecciones visuales convencionales, demostrando el valor añadido de la termografía cuantitativa automatizada.

6.3 Comparación con Técnicas Alternativas

El rendimiento del sistema propuesto se comparó con cuatro técnicas alternativas documentadas en la literatura para detección de daños mediante procesamiento de imágenes :

Tabla 5: Comparación de Técnicas de Detección de Daños

Técnica	Precisión Reportada	Ventajas	Limitaciones
Sistema Propuesto (SVM + Procesamiento Térmico)	87.3%	Alto desempeño, interpretabilidad, detección de zonas calientes	Sensibilidad media a variaciones en calidad de imagen
Umbralización de Otsu	72.1%	Simplicidad computacional, no requiere entrenamiento	Sensible a ruido y heterogeneidad de fondo
Campos Aleatorios de Markov	79.5%	Modela relaciones espaciales entre píxeles	Complejidad computacional elevada
Detección Color RGB por	68.3%	Efectivo para patrones de color distintivos	Pobre desempeño con iluminación variable
Clustering means K-	75.8%	No supervisado, no requiere datos etiquetados	Número de clusters debe predefinirse

El sistema propuesto demostró un equilibrio favorable entre precisión, eficiencia computacional y robustez, superando consistentemente a las técnicas alternativas en la tarea específica de clasificación de estados térmicos en equipos eléctricos.

7. Conclusiones y Trabajo Futuro

7.1 Conclusiones Principales

El desarrollo e implementación del sistema de detección de fallas en equipos eléctricos mediante procesamiento de imágenes térmicas demuestra la viabilidad técnica y el valor práctico de los enfoques de visión artificial para aplicaciones en el sector energético. Las conclusiones principales del proyecto se resumen a continuación:

- La combinación de **técnicas clásicas de procesamiento de imágenes** (morfología matemática, detección de contornos) con **algoritmos de aprendizaje automático** (SVM) permite desarrollar sistemas de diagnóstico térmico con alto nivel de precisión (87.3% en validación experimental) y capacidad de generalización.
- El enfoque de **detección basada en percentiles** para identificación de zonas calientes demuestra robustez frente a variaciones en rangos absolutos de temperatura, adaptándose automáticamente a diferentes condiciones operativas y características de equipos.
- La **integración del criterio humano** dentro del flujo de trabajo mediante el módulo interactivo de validación facilita la adopción progresiva del sistema y genera simultáneamente conjuntos de datos anotados de alta calidad para mejora continua.
- La **arquitectura modular** del sistema permite su adaptación a diferentes contextos operativos dentro del sector energético, desde inspección con drones hasta monitoreo continuo en subestaciones, demostrando versatilidad y escalabilidad.

La inclusión de datasets en el ecosistema de entrenamiento potencia significativamente la capacidad de generalización del sistema de diagnóstico térmico. Mientras que el dataset de motores eléctricos proporciona el caso de uso principal, los datasets adicionales ofrecen:

- Fotovoltaico: Extensión a tecnologías de generación renovable
- Infrarrojo general: Validación de robustez ante variabilidad operativa

Esta diversidad de fuentes asegura que el sistema no se especialice excesivamente en un tipo particular de equipo o anomalía, manteniendo flexibilidad diagnóstica para diversas aplicaciones en el sector energético. La arquitectura del código, con sus rutinas de carga de datos genéricas, facilita la incorporación progresiva de estos y otros datasets especializados, apoyando así la evolución continua del modelo conforme se disponga de más datos anotados en el dominio de la termografía eléctrica.

El sistema representa una alternativa efectiva a los procedimientos de inspección térmica tradicionales, ofreciendo ventajas significativas en términos de escalabilidad, consistencia, velocidad de procesamiento y capacidad de documentación automatizada, al tiempo que reduce la dependencia de especialistas humanos altamente capacitados.

7.2 Limitaciones Identificadas

Durante el desarrollo y validación del sistema, se identificaron varias limitaciones que representan oportunidades de mejora para futuras iteraciones:

- La efectividad del sistema está sujeta a la **calidad y consistencia** de las imágenes térmicas de entrada, con degradación del desempeño frente a variaciones significativas en distancia de captura, ángulo u obstrucciones parciales.
- El enfoque de clasificación actual opera principalmente a nivel de imagen completa, con **capacidad limitada para identificar múltiples anomalías coexistentes** en diferentes regiones de la misma imagen.
- La **interpretabilidad** de las decisiones del modelo, aunque superior a approaches de caja negra como redes neuronales profundas, sigue siendo un desafío para casos fronterizos o de baja confianza.
- El sistema actual requiere **configuración manual de parámetros** de sensibilidad (percentil, área mínima) que podrían optimizarse automáticamente basándose en características específicas del equipo bajo análisis.

Estas limitaciones no invalidan la utilidad práctica del sistema actual, pero definen direcciones claras para investigación y desarrollo futuro.

7.3 Direcciones Futuras

Basándose en los resultados obtenidos y las limitaciones identificadas, se proponen las siguientes direcciones para trabajo futuro:

- **Implementación de arquitecturas de deep learning:** Explorar el uso de **Redes Neuronales Convolucionales (CNN)** especializadas en imágenes térmicas, potencialmente mediante enfoques de **aprendizaje por**

transferencia a partir de modelos pre-entrenados en dominios visuales genéricos .

- **Sistemas de detección multi-escala:** Desarrollar arquitecturas que combinen análisis a nivel global (clasificación de estado general) y local (detección y caracterización de anomalías específicas) en un marco unificado.
- **Integración de datos multi-modal:** Combinar imágenes térmicas con otros tipos de datos sensoriales (vibración, ultrasonido, análisis de gases) para mejorar la confiabilidad del diagnóstico mediante fusión sensorial.
- **Plataformas de despliegue Edge:** Optimizar el sistema para despliegue en hardware embebido especializado, permitiendo el análisis en tiempo real directamente en drones o cámaras fijas sin dependencia de conectividad de red.
- **Sistemas de alerta temprana predictiva:** Desarrollar modelos que, más allá de detectar anomalías existentes, puedan predecir la evolución futura de patrones térmicos para anticipar fallas incipientes antes de que alcancen niveles críticos.

La implementación de estas mejoras tiene el potencial de transformar significativamente las prácticas de mantenimiento en el sector energético, aumentando la confiabilidad de la infraestructura eléctrica mientras se optimizan los recursos destinados a actividades de mantenimiento predictivo y correctivo.

8. Referencias Bibliográficas

1. Pontificia Universidad Católica de Chile. "Procesamiento de Imágenes". Coursera.
2. UnitX Labs. "Cómo funciona la clasificación en los sistemas de visión artificial".
3. [Unite.AI](#). "Las 10 mejores bibliotecas de procesamiento de imágenes en Python".
4. DIY Coding. "Color Models in Image Processing: Understanding RGB and HSV for Computer Vision". Medium.
5. Chen, X. et al. "Damage detection with image processing: a comparative study". Earthquake Engineering and Engineering Vibration, 22, 333-345 (2023).
6. [Neptune.ai](#). "Top 8 Image-Processing Python Libraries Used in Machine Learning".
7. Documento sobre "Modelo de color RGB". Scribd.

8. Raúl PZS. "Clasificación de imágenes con métodos clásicos y redes neuronales". Medium.
9. UnitX Labs. "Bibliotecas clave de procesamiento de imágenes para sistemas avanzados de visión artificial".
10. ADS Harvard. "Damage detection with image processing: a comparative study". Abstract.
11. Python16. (2023). "Electric Motor Thermal Image Fault Diagnosis". Kaggle. Disponible en: <https://www.kaggle.com/datasets/python16/electric-motor-thermal-image-fault-diagnosis/data>
12. Gabriel, M. (2023). "Photovoltaic System Thermography". Kaggle. Disponible en: <https://www.kaggle.com/datasets/marcosgabriel/photovoltaic-system-thermography>
13. Programmer Lead, S. (2023). "Infrared Thermal Image Dataset". Kaggle. Disponible en: <https://www.kaggle.com/datasets/s3programmerlead/infrared-thermal-image-dataset>